

RTAI_Assignment4

2021480016 이현승

1. 모델, 데이터 셋, 검증 속성

이번 과제에서 MNIST 손글씨 숫자 분류를 위해 학습된 간단한 MLP 모델을 검증 대상으로 선택했다. 모델의 구조는 다음과 같다.

입력 (784) → Linear → ReLU → Linear → 출력 (10)

- FC1: 784 → 64, ReLU 활성화 함수 적용

- FC2: 64 → 10 (각 클래스에 대한 logit 출력)

해당 모델은 Adam 옵티마이저와 CE Loss를 사용하여 1 epoch 학습 후 ONNX 형식(my_mlp.onnx)로 보냈다. Assignment 3에서 Marabou로 검증했던 동일한 모델을 재사용했는데, 두 도구의 성능을 같은 조건에서 비교하기 위함이었다.

데이터셋은 MNIST 테스트셋을 사용했으며, 0번부터 49번까지 총 50개의 샘플을 검증했다. CPU 환경에서 현실적인 실행 시간 안에 결과를 얻기 위해 샘플 수를 50개로 제한했다. 입력 정규화는 mean=0.1307, std=0.3081을 적용했다.

검증 속성은 L^∞ robustness로 설정했다. 각 테스트 샘플 x 에 대해, $\epsilon=0.03$ 크기의 L^∞ -ball 안에 있는 어떤 입력 x' 을 넣어도 모델의 예측 클래스가 바뀌지 않음을 확인하는 것이다.

2. 검증 결과 및 해석

Marabou와의 공정한 비교를 위해 α, β -Crown을 CPU 환경에서 실행했다.

50개 샘플에 대한 검증 결과는 다음과 같다.

```
(RTAI4) c:\RTAI\RTAI_assignment4>python test.py
=====
 $\alpha, \beta$ -Crown Verification: SimpleMLP on MNIST
Model   : my_mlp.onnx (784 -> 64 -> ReLU -> 10)
Dataset : MNIST (50 test samples)
Property: L-inf robustness, epsilon=0.03
=====
Running verifier... (this may take a moment)

Total verification time: 21.33s

=====
Verification Results Summary
=====
Total samples      : 50
safe-incomplete    : 32 (verified safe by  $\alpha$ -Crown)
unsafe-pgd         : 18 (falsified by PGD attack)
timeout            : 0 (not concluded within time limit)
```

safe-incomplete (64%):

초기 CROWN 단계에서 선형 완화(linear relaxation)를 통해 안전성이 증명된 경우다. Branch-and-Bound까지 진행하지 않고도 robustness를 확인할 수 있었으며,

샘플당 평균 약 0.24초가 소요됐다.

unsafe-pgd (36%):

PGD(Projected Gradient Descent) 공격이 $\epsilon=0.03$ 범위 안에서 예측 클래스를 바꾸는 적대적 예제를 찾아낸 경우다. 반례가 발견되면 즉시 종료되기 때문에 평균 0.02초로 매우 빠르게 처리됐다.

timeout (0%):

시간 초과 케이스는 없었다. $\epsilon=0.03$ 수준에서는 incomplete verification만으로 충분히 결론을 낼 수 있었다는 의미다.

전체 샘플의 36%가 falsified된 것은 $\epsilon=0.03$ 이 이 모델의 실제 robustness 한계를 넘는다는 것을 보여준다. 모델이 adversarial training 없이 표준 방식으로만 학습되었기 때문에, 작은 perturbation 에도 예측이 흔들리는 샘플이 상당수 존재했다.

3. α,β -Crown vs Marabou 비교

-속도 비교:

두 도구는 검증하는 속성의 형태가 달라 직접적인 속도 비교는 어렵다. Marabou는 하나의 추상적인 입력 영역에 대한 단일 속성을 검증하는 반면, α,β -Crown은 50개의 개별 샘플 각각에 대해 robustness를 검증한다. α,β -Crown이 CPU 환경에서도 50개 샘플을 8초 안에 처리한 점은 인상적이었다.

설정 방식에서도 차이가 느껴졌다. Marabou는 입력/출력 변수에 직접 부등식 제약 조건을 코드로 작성해야 해서 처음 다루기가 까다로웠다. 반면 α,β -Crown은 YAML 파일에 모델 경로, 데이터셋, epsilon 값 등을 선언하면 나머지는 도구가 알아서 처리해줘서 사용하기 훨씬 편했다.

4. α,β -Crown의 강점과 한계

이번 과제를 통해 α,β -Crown이 검증 파이프라인이 잘 설계 되어 있고 GPU 가속을 지원해 대규모 네트워크도 검증할 수 있다는 것을 배웠으나, safe-imcomplete 결과 처럼 완벽한 증명을 위해서 BaB 탐색 공간이 폭발적으로 증가한다는 것과, submodule 및 CUDA 버전 호환 문제등의 어려움을 알 수 있었다.